

# $M_0$ : Un espace métrique commun et unifié pour l'évaluation de partitions crédales

## $M_0$ : A Common and Unified Metric Space for Evaluating Credal Partitions

Hamdjia<sup>1</sup>

V. Antoine<sup>1</sup>

J. Koko<sup>1</sup>

<sup>1</sup>LIMOS, UMR 6158 CNRS, Université Clermont Auvergne, Clermont Auvergne INP, F-63000 Clermont-Ferrand, France

\_hamdjia@etu.uca.fr

violaine.antoine@limos.fr

**Résumé :** L'évaluation des partitions crédales produites par des algorithmes de clustering évidentiel pose un problème concret, à savoir que chaque algorithme minimise sa propre fonction objectif dans son propre espace métrique natif, ce qui rend toute comparaison directe entre partitions dépourvue de sens. Cet article établit formellement que l'espace  $M_0$  des fonctions de masse non-normalisées, muni de la distance de Jousselme, est un espace métrique borné, compact et complet et introduit trois indices de validations. Cette structure, construite sur la géométrie simpliciale naturelle de l'espace des fonctions de masse de base (BBA), fournit un cadre de référence commun et indépendant de l'algorithme producteur pour évaluer et comparer toute partition crédale, quelle que soit la métrique interne de l'algorithme producteur.

**Mots-clés :** Théorie des fonctions de croyance, clustering évidentiel, distance de Jousselme, espace métrique.

**Abstract:** Evaluating credal partitions from evidential clustering algorithms raises a concrete challenge : each algorithm minimises its own objective in its own native metric space, making direct comparison meaningless. This paper formally establishes that the space  $M_0$  of non-normalised mass functions, equipped with the Jousselme distance, is a bounded, compact and complete metric space and introduces three validation indices. This structure, built on the natural simplicial geometry of the basic belief assignments (BBA) space, provides a common, algorithm-independent reference framework for evaluating and comparing any credal partition, regardless of the producing algorithm's internal metric.

**Keywords:** Belief function theory, evidential clustering, Jousselme distance, metric space.

## 1 Introduction

Le clustering évidentiel s'appuie sur la théorie des fonctions de croyance de Dempster-Shafer pour produire des partitions crédales plus expressives que celles du clustering classique. Plutôt que d'affecter chaque objet à un seul cluster, un algorithme générant une partition crédale lui attribue une *fonction de masse de base* (BBA) sur l'ensemble des clusters. Cette BBA permet d'exprimer une appartenance certaine à un cluster unique, mais aussi une ambiguïté entre plusieurs clusters (un méta-cluster), ou encore la nature atypique de l'objet.

De nombreux algorithmes de clustering évidentiel ont été proposés [16] et ont été utilisés dans différents domaines tels que le médical [7, 14] ou l'analyse de réseaux sociaux [18]. Parmi ces algorithmes, ECM [10] adapte le principe des *c*-moyennes floues en minimisant une inertie euclidienne pondérée par les masses. Plusieurs variantes ont ensuite été proposées. Ainsi, ECM+ [1] remplace la distance euclidienne par une distance de Mahalanobis adaptative, mieux adaptée aux clusters de forme elliptique, et ECMdd [17] est un algorithme purement relationnel qui opère directement sur une matrice de dissimilarité et sélectionne des médoïdes réels, sans construire de centroïdes géométriques abstraits.

Ces trois algorithmes produisent des BBA, donc des points dans le même espace  $M_0$ , mais chacun optimise une fonction définie dans son propre espace métrique natif qui est l'inertie euclidienne pour ECM, l'inertie de Mahalanobis pour ECM+, stress sur dissimilarité pour ECMdd. Cette hétérogénéité rend toute comparaison di-

recte très difficile. De fait, évaluer la partition d'ECM+ avec le critère interne d'ECM revient à juger un résultat selon un objectif qu'il n'a jamais cherché à satisfaire.

**Contribution.** Nous introduisons trois indices de validation CSJ, C3R et SDQI pour l'évaluation de partitions crédables dans l'espace métrique  $(M_0, d_J)$ . La bornitude, la compacité et la complétude de cet espace, que nous établissons formellement, en font un référentiel naturel où ces indices sont intrinsèquement bien posés et comparables entre algorithmes.

La suite est organisée comme suit. La section 2 établit la structure géométrique de  $M_0$  comme simplexe dans un espace de dimension réduite. La section 3 établit les propriétés métriques et topologiques de  $(M_0, d_J)$  et introduit les indices proposés. La section 4 illustre les expériences réalisées.

## 2 L'espace $M_0$ et la distance de Jousselme

En clustering évidentiel, chaque objet  $x_i$  reçoit une *fonction de masse* (BBA)  $m_i : 2^\Omega \rightarrow [0, 1]$  sur les parties du référentiel  $\Omega = \{C_1, \dots, C_k\}$ , vérifiant  $m(\emptyset) + \sum_{j=1}^{N-1} m_j = 1$  avec  $N = 2^k$ . La masse  $m_i(A)$  pour un sous-ensemble  $A$  signifie que  $x_i$  appartient au méta-cluster  $A$  sans pouvoir distinguer ses membres ;  $m_i(\emptyset) > 0$  indique un objet potentiellement en conflit (outlier). Si  $m(\emptyset) = 0$ , la BBA est dite normalisée.

La contrainte de normalisation contient une égalité linéaire qui permet d'éliminer  $m(\emptyset)$  dès que les masses non vides sont connues. En posant  $u = (m_1, \dots, m_{N-1})^\top \in \mathbb{R}^{N-1}$ , on obtient :

$$m(\emptyset) = 1 - \mathbf{1}^\top u, \quad \mathbf{1} = (1, \dots, 1)^\top, \quad (1)$$

ce qui montre que toute BBA est entièrement décrite par un vecteur  $u \in \mathbb{R}^{N-1}$  où la masse de conflit s'en déduit automatiquement. L'espace des BBA valides dans ce repère réduit est  $M_0(2^\Omega) := \{u \in \mathbb{R}^{N-1} : u_j \geq 0 \forall j, \mathbf{1}^\top u \leq 1\}$ , avec la condition  $\mathbf{1}^\top u \leq 1$  qui reflète  $m(\emptyset) \geq 0$ .

**Théorème 1** (Structure de  $M_0$  [6]).  $M_0(2^\Omega)$  est le simplexe standard  $(N-1)$ -dimensionnel dans  $\mathbb{R}^{N-1}$ , de  $N$  sommets :  $e_0 = (0, \dots, 0)^\top$ , correspondant au conflit pur ( $m(\emptyset) = 1$ ), et, pour  $j = 1, \dots, N-1$ , le  $j$ -ème vecteur canonique  $e_j$  de  $\mathbb{R}^{N-1}$ , correspondant à la BBA qui attribue toute sa masse à l'élément focal  $A_j \in 2^\Omega \setminus \{\emptyset\}$  (i.e.  $m(A_j) = 1$ ).

*Preuve.* Pour tout  $u \in M_0$ , on a  $u = m(\emptyset) e_0 + \sum_j m_j e_j$  avec tous les coefficients positifs de somme 1. Les vecteurs  $e_j - e_0$  forment la base canonique de  $\mathbb{R}^{N-1}$ , ce qui établit l'indépendance affine des  $N$  sommets.  $\square$

Ce résultat donne une géographie claire de l'espace des partitions : les sommets  $e_1, \dots, e_{N-1}$  correspondent aux affectations certaines (un seul cluster ou méta-cluster), et  $e_0$  représente le conflit total (outlier parfait). Une partition bien séparée concentre ses BBAs au voisinage des sommets singletons, tandis que les zones d'ambiguïté produisent des BBAs proches des sommets de méta-clusters.

Pour  $K = 2$  par exemple, avec  $\Omega = \{C_1, C_2\}$ , le vecteur réduit est  $u = (m_1, m_2, m_{12})^\top \in \mathbb{R}^3$ . Nous pouvons illustrer les quatre situations suivantes :

|                                                       |                                         |
|-------------------------------------------------------|-----------------------------------------|
| $u^{(1)} = (0.9, 0, 0.1), \quad m(\emptyset) = 0$     | objet presque certain dans $\omega_1$ , |
| $u^{(2)} = (0, 0.8, 0.2), \quad m(\emptyset) = 0$     | objet presque certain dans $\omega_2$ , |
| $u^{(3)} = (0, 0, 1.0), \quad m(\emptyset) = 0$       | ignorance totale (méta-cluster),        |
| $u^{(4)} = (0.4, 0.2, 0.1), \quad m(\emptyset) = 0.3$ | conflit modéré (outlier potentiel).     |

Il faut noter que  $u^{(4)}$  n'est pas normalisé : c'est précisément ce type de BBA que les algorithmes tels que sECMdd [17] produisent pour signaler un outlier, et que  $M_0$  arrive à représenter. Géométriquement, tout  $u \in M_0$  se lit comme un point sur le segment joignant  $e_0$  à sa projection normalisée  $\hat{u} = u / (1 - m(\emptyset)) \in M$ ,

c'est-à-dire que plus  $m(\emptyset)$  est élevée, plus l'objet est proche du sommet de conflit en restant sur la droite qui relie  $e_0$  à  $\hat{u}$ , et donc on a la relation :

$$u = m(\emptyset) \cdot e_0 + (1 - m(\emptyset))\hat{u}, \quad \text{où} \quad \hat{u} = \frac{u}{1 - m(\emptyset)} \in M, \quad (2)$$

le point  $u$  se présente comme une combinaison barycentrique entre le sommet conflit  $e_0$  et sa projection  $\hat{u}$  étant donné que la somme des poids donne 1. En considérant les vecteurs position des différents points, dont celui du point  $e_0$  est le vecteur nul, nous avons donc :

$$m(\emptyset)e_0 + (1 - m(\emptyset))\hat{u} = m(\emptyset)\mathbf{0} + (1 - m(\emptyset))\left(\frac{u}{1 - m(\emptyset)}\right) = \mathbf{0} + u = u. \quad (3)$$

avec  $m(\emptyset) \neq 1$  sinon  $u$  sera confondu au point  $e_0$ . Pour mesurer la proximité entre deux BBAs dans  $M_0$ , on s'appuie sur la similarité de Jaccard entre sous-ensembles et définie par [9, 8] :

$$D_{AB} = \frac{|A \cap B|}{|A \cup B|} \quad A, B \neq \emptyset, \quad D_{A\emptyset} = D_{\emptyset B} = 0 \quad \text{et} \quad D_{\emptyset\emptyset} = 1. \quad (4)$$

La matrice de Jaccard étendue  $D \in \mathbb{R}^{N \times N}$ , indexée sur tous les sous-ensembles y compris  $\emptyset$ , a une structure par blocs de la forme  $D = \text{diag}(1, D^*)$ , où  $D^* \in \mathbb{R}^{(N-1) \times (N-1)}$  est la matrice de Jaccard restreinte aux éléments non vides qui est une matrice symétrique et définie positive [2].

La réduction (1) permet de calculer  $d_J$  depuis le vecteur réduit  $u \in \mathbb{R}^{N-1}$  sans reconstruire le vecteur de dimension  $N = 2^k$ . La formule résultante fait apparaître deux composantes :  $\mathbf{1}\mathbf{1}^\top$  mesure la variation de masse totale engagée hors conflit (ex. deux BBAs dont l'une alloue 90% et l'autre 45% de sa masse à des éléments non vides sont pénalisées par ce terme), et  $D^*$  pondère les écarts par la similarité de Jaccard entre éléments focaux (deux BBAs qui diffèrent sur  $\{C_1\}$  et  $\{C_2\}$ , disjoints, sont plus pénalisées que deux BBAs qui diffèrent sur  $\{C_1\}$  et  $\{C_1, C_2\}$ , Jaccard = 1/2). Ces deux composantes motivent directement la conception finale des indices de la section 3. Ainsi donc pour deux BBAs  $u, u' \in M_0$  et  $\Delta = u - u'$ , la première coordonnée du vecteur différence ( $\tilde{\Delta}$ ) dans  $\mathbb{R}^N$  vaut  $-\mathbf{1}^\top \Delta$  (variation de masse de conflit) car chaque vecteur  $\tilde{u}$  dans  $\mathbb{R}^N$  a pour coordonnées  $(1 - \mathbf{1}^\top u, u)^\top$  grâce à la relation  $m(\emptyset) = 1 - \mathbf{1}^\top u$ . Le vecteur différence complet dans  $\mathbb{R}^N$  s'écrit donc :

$$\tilde{\Delta} = \tilde{u} - \tilde{u}' = \begin{pmatrix} 1 - \mathbf{1}^\top u \\ u \end{pmatrix} - \begin{pmatrix} 1 - \mathbf{1}^\top u' \\ u' \end{pmatrix} = \begin{pmatrix} -\mathbf{1}^\top \Delta \\ \Delta \end{pmatrix},$$

En développant  $\tilde{\Delta}^\top D \tilde{\Delta}$  à l'aide de la structure par blocs :

$$\tilde{\Delta}^\top D \tilde{\Delta} = (\mathbf{1}^\top \Delta)^2 + \Delta^\top D^* \Delta = \Delta^\top \underbrace{(\mathbf{1}\mathbf{1}^\top + D^*)}_{=: J} \Delta,$$

ce qui définit la matrice  $J \in \mathbb{R}^{(N-1) \times (N-1)}$ . La distance de Jousselme [8] entre  $u$  et  $u'$  se reformule alors :

$$d_J(u, u') = \sqrt{\frac{1}{2} \Delta^\top J \Delta}, \quad J = \mathbf{1}\mathbf{1}^\top + D^*, \quad \Delta = u - u' \in \mathbb{R}^{N-1}. \quad (5)$$

Pour que (5) définisse bien une *distance* (et non une pseudo-distance), il faut  $J \succ 0$ , or pour tout  $v \neq 0 \in \mathbb{R}^{N-1}$  :

$$v^\top J v = (\mathbf{1}^\top v)^2 + v^\top D^* v,$$

le premier terme est un carré réel ( $\geq 0$ ) et le second est strictement positif car  $D^* \succ 0$  [2] et  $v \neq 0$  : donc  $J \succ 0$ , et  $d_J$  est bien une distance sur  $M_0$ .

### 3 Propriétés de $(M_0, d_J)$ et indices d'évaluation

#### 3.1 Propriétés topologiques de l'espace $(M_0, d_J)$

L'espace  $(M_0, d_J)$  possède quatre propriétés topologiques. Contrairement à la topologie euclidienne pour laquelle la compacité de  $M_0$  est immédiate (Heine-Borel), ces propriétés pour  $d_J$  reposent sur  $J \succ 0$  : si  $D^*$  n'était que semi-définie positive,  $d_J$  ne serait pas une distance au sens strict et la complétude ferait défaut. Puisque  $J \succ 0$ , la forme  $\Delta \mapsto (\Delta^\top J \Delta)^{1/2}$  est une norme sur  $\mathbb{R}^{N-1}$ , et  $d_J$  en hérite les quatre axiomes d'une distance (positivité, séparation, symétrie, inégalité triangulaire), ce qui fait de  $(M_0, d_J)$ , un espace métrique.

Pour un point  $u \in M_0$ , la définition de l'espace donne  $\|u\|_1 = \sum_{i=1}^n |u_i| \leq 1$ , donc  $\|u - u'\|_1 \leq 2$  pour tout couple (par inégalité triangulaire). L'équivalence des normes en dimension finie [3] assure l'existence d'une constante  $C_1 > 0$  telle que  $d_J(u, u') \leq 2C_1$  pour tous  $u, u' \in M_0$ , ainsi le diamètre de l'espace est fini, ce qui fait de  $(M_0, d_J)$  un espace borné.

$M_0$  est l'intersection de  $N$  demi-espaces fermés (les  $N - 1$  contraintes  $u_j \geq 0$  et la contrainte  $\mathbf{1}^\top u \leq 1$ ), donc un sous-ensemble fermé de  $\mathbb{R}^{N-1}$  [13]. Fermé et borné en dimension finie, il est compact par le théorème de Heine-Borel [13]. Une des conséquences directes est que toute fonction d'évaluation continue définie sur  $M_0$  atteint son minimum et son maximum. De plus, sachant que tout espace métrique compact est complet [13],  $(M_0, d_J)$  est également un espace complet.

Le tableau 1 résume ces quatre propriétés. Ces propriétés sont indépendantes de l'algorithme producteur, quelle

TABLEAU 1 – Propriétés de  $(M_0, d_J)$  et leurs implications pour l'évaluation crédale.

| Propriété       | Justification                            | Implication pratique                                        |
|-----------------|------------------------------------------|-------------------------------------------------------------|
| Espace métrique | $J \succ 0$ induit une norme             | Indices de compacité et séparation toujours cohérents       |
| Borné           | $\ u\ _1 \leq 1$ , équiv. des normes [3] | Les indices ne divergent jamais, même sous bruit extrême    |
| Compact         | Fermé + borné + dim. finie [13]          | Tout indice continu atteint son extremum exact sur $M_0$    |
| Complet         | Compact $\Rightarrow$ complet [13]       | Centroïdes crédaux toujours définis ; pas de dégénérescence |

que soit la métrique interne utilisée, les BBA résultantes appartiennent toutes au même espace  $(M_0, d_J)$ . Cette indépendance vis-à-vis de la métrique native de l'algorithme producteur rend possible la définition d'indices de validation intrinsèques, opérant directement dans la géométrie du simplexe plutôt que dans l'espace des données.

#### 3.2 Indices d'évaluation

Les propriétés topologiques de l'espace métrique  $(M_0, d_J)$  établissent un cadre théorique où nous y définissons trois indices de validation de clustering, spécifiquement conçus pour exploiter la géométrie du simplexe  $M_0$ .

**Indice CSJ (Credal Silhouette with Jousselme).** Le premier indice s'inspire de la silhouette floue [4, 11], reconnue pour pénaliser les objets situés dans des zones de chevauchement. Toutefois, la pondération classique de la silhouette floue peine à distinguer l'imprécision du bruit pur.

La silhouette crédale de Jousselme (**CSJ**) résout cette limite en transposant l'évaluation dans l'espace  $M_0$ , où la distance  $d_J$  évalue la proximité sémantique des états de croyance. Pour éviter que les objets ambigus ou aberrants ne corrompent l'évaluation des noyaux denses, le CSJ introduit un poids de conviction  $w_i$ . Ce poids doit tendre vers 0 si le point est imprécis ou bruité, et posséder une monotonie inverse vis-à-vis de la cardinalité de l'élément focal dominant. Sa formulation est la suivante :

$$w_i = m_i(\{C_{k^*(i)}\}) \cdot (1 - m_i(\emptyset)), \quad (6)$$

où  $k^*(i) = \arg \max_k m_i(\{C_k\})$  représente le cluster dominant de l'objet  $i$ . Ce poids agit comme un double filtre :

- La masse singleton dominante  $m_i(\{C_{k^*(i)}\})$  s'effondre face à l'imprécision, l'algorithme transférant la masse vers des méta-clusters de type  $\{C_k, C_l\}$ .
- Le terme  $(1 - m_i(\emptyset))$  agit comme un filtre anti-conflit. Si un point est un rejet (*outlier*), sa masse  $m_i(\emptyset)$  tend vers 1, annulant ainsi son influence.

L'indice CSJ s'exprime alors comme la moyenne pondérée des silhouettes individuelles :

$$CSJ = \frac{\sum_{i=1}^n w_i^\alpha \cdot s_J(i)}{\sum_{i=1}^n w_i^\alpha}, \quad (7)$$

où  $s_J(i)$  évalue la qualité de l'affectation géométrique dans  $M_0$ , définie par :

$$s_J(i) = \frac{b_J(i) - a_J(i)}{\max(a_J(i), b_J(i))}, \quad (8)$$

$$a_J(i) = \frac{1}{|P_{k^*(i)}| - 1} \sum_{j \in P_{k^*(i)}, j \neq i} d_J(m_i, m_j), \quad b_J(i) = \min_{l \neq k^*(i)} \frac{1}{|P_l|} \sum_{j \in P_l} d_J(m_i, m_j), \quad (9)$$

avec  $P_k$  l'ensemble des objets ayant  $k$  comme cluster dominant et le coefficient  $\alpha \geq 1$  qui règle la sélectivité du poids. Pour  $\alpha = 1$ , tous les objets contribuent proportionnellement à leur conviction et des valeurs plus élevées concentrent l'évaluation sur les objets les plus certains.

**Indice C3R (Credal Compactness, Conflict and Separation Ratio).** Le second indice repose sur une minimisation du rapport entre compacité et séparation, un principe similaire à l'indice de Xie-Beni [15]. Opérer dans l'espace initial des données pose cependant des limites : explosion des valeurs en cas de dilatation des données, incapacité à évaluer des algorithmes purement relationnels (sans centroïdes spatiaux), et incommensurabilité entre algorithmes utilisant des métriques différentes (ex. Euclidienne vs Mahalanobis). L'indice **C3R** contourne ces biais en opérant directement sur  $(M_0, d_J)$ .

La compacité n'y est pas mesurée par rapport aux centroïdes empiriques, mais par rapport aux sommets purs  $e_k$  du simplexe (où  $m(\{C_k\}) = 1$ ). Un centroïde empirique absorbant l'incertitude moyenne locale, il est théoriquement plus juste de minimiser la distance entre un point et le sommet pur qu'il atteindrait en l'absence totale d'ambiguïté. La composante de compacité est donnée par :

$$\text{Compact}_J = \frac{1}{n} \sum_{i=1}^n \sum_{k=1}^K m_i(\{C_k\})^2 \cdot d_J(m_i, e_k)^2. \quad (10)$$

La pondération par  $m_i(\{C_k\})^2$  accentue l'écart d'influence entre un objet certain (ex.  $0.9^2 = 0.81$ ) et un objet hésitant (ex.  $0.4^2 = 0.16$ ).

La composante de séparation mesure l'écartement minimal au carré entre deux centroïdes crédaux  $c_k$  et  $c_l$  dans l'espace  $M_0$  :

$$\text{Sep}_{J\text{-rel}} = \min_{k \neq l} d_J(c_k, c_l)^2 \quad (11)$$

où le centroïde  $c_k = \frac{1}{|P_k|} \sum_{i \in P_k} u_i \in M_0$  est calculé comme la moyenne arithmétique des vecteurs de masse du cluster  $k$ . Afin de sanctionner les algorithmes qui rejetteraient excessivement les objets au profit d'une compacité artificielle, on introduit un terme de pénalité  $\text{Conflit}_J = \frac{1}{n} \sum_{i=1}^n m_i(\emptyset)$ , qui représente le taux moyen de rejet de la partition, pondéré par le paramètre de tolérance  $\lambda \geq 0$ . L'expression complète du C3R est donc :

$$C3R = (\text{Compact}_J + \lambda \cdot \text{Conflit}_J) / \text{Sep}_{J\text{-rel}} \quad (12)$$

**Indice SDQI (Spatial-Evidential Distance Quality Index).** Contrairement aux deux approches précédentes qui adaptent des concepts existants, le **SDQI** exploite la structure géométrique intrinsèque de  $M_0$ . Il s'articule autour de trois facteurs.

Le premier facteur évalue la compacité de la partition en s'affranchissant du conflit grâce à l'équation (2). Il correspond au complément à 1 de l'inertie intra-cluster projetée (NPQ) :

$$NPQ = \max(0, 1 - intra\_sq) \quad \text{avec} \quad intra\_sq = \frac{1}{n} \sum_{i=1}^n d_J(\hat{u}_i, \hat{c}_{k^*(i)})^2, \quad (13)$$

où  $\hat{c}_{k^*(i)}$  désigne le centroïde des projections du cluster d'appartenance de l'objet  $i$ . Ce facteur permet de vérifier si les points convergent vers leurs centroïde après projections.

Le second facteur vérifie que l'imprécision (les méta-clusters) modélise de véritables zones frontalières et non des aberrations topologiques. Il repose sur la corrélation de Spearman ( $\rho_S$ ) entre l'imprécision moyenne allouée à une paire de clusters ( $\mu_{kl}$ ) et la proximité spatiale de leurs centroïdes ( $-d_J(c_k, c_l)$ ), il permet d'évaluer la monotonie, pas nécessairement linéaire, entre l'imprécision et la proximité des clusters [12, 5]. :

$$ISI = (1 + \rho_S(\{\mu_{kl}\}, \{-d_J(c_k, c_l)\}))/2 \quad (14)$$

Ce terme de corrélation normalisé dans  $[0, 1]$  permet d'interpréter les comportements limites de l'algorithme :

- **Cohérence topologique optimale** ( $\rho_S = +1 \implies ISI = 1$ ) : Les clusters sémantiquement les plus proches reçoivent la plus forte masse d'imprécision. L'incertitude est géométriquement justifiée, l'indice conserve sa valeur maximale.
- **Incohérence sévère** ( $\rho_S = -1 \implies ISI = 0$ ) : L'algorithme place sa plus forte incertitude entre les clusters les plus éloignés, reliant artificiellement des zones disjointes. La partition subit alors une pénalité sévère.

Le SDQI final est défini par le produit de ces facteurs : la qualité de la structure géométrique (NPQ), la proportion de maintien des données valides, et la pertinence physique de l'incertitude ( $1 + ISI$ ). Son expression est :

$$SDQI = \frac{1}{2} NPQ \times (1 - \mu_\emptyset) \times (1 + ISI) \quad (15)$$

où  $\mu_\emptyset = \frac{1}{n} \sum_{i=1}^n m_i(\emptyset)$  représente le taux de conflit moyen de la partition. L'indice SDQI renvoie un score dans l'intervalle  $[0, 1]$  qu'il convient de maximiser.

Les trois indices satisfont :  $CSJ \in [-1, 1]$  (à maximiser),  $C3R \in [0, +\infty)$  (à minimiser) et  $SDQI \in [0, 1]$  (à maximiser).

## 4 Expérimentations

Pour illustrer empiriquement la robustesse et la pertinence de notre cadre d'évaluation dans  $(M_0, d_J)$ , nous proposons une série d'expérimentations. Puisque nos indices opèrent indépendamment de la mécanique interne des algorithmes, nous mobilisons en premier lieu l'algorithme sECMdd (*single-medoid Evidential c-medoids*). Contrairement aux approches géométriques traditionnelles, sECMdd est purement relationnel, il ne requiert pas le calcul de centroïdes abstraits et opère directement sur une matrice de dissimilarités pour sélectionner des représentants réels (les médoïdes) parmi les objets [17], ce qui le rend idéal pour éprouver notre cadre topologique non spatial.

Nos premières expériences s'appuient sur le jeu de données synthétique *Overlap* [17], composé de trois cercles superposés contenant chacun 361 points (Figure 1). Bien que simple, ce jeu de données est adapté pour observer le comportement de l'algorithme face à l'ambiguïté dans des zones de fort chevauchement. L'algorithme sECMdd a été configuré avec les hyperparamètres  $\alpha = 2$  pour le contrôle de la tolérance à l'imprécision,  $\beta = 2$  pour l'exposant de fuzzification, et un seuil de dissimilarité  $\delta = 100$  pour l'isolement des rejets. Le paramètre

$\eta$ , régulant la distinction des aberrations lors de la sélection des médoïdes, a été fixé à 1. La Figure 1 illustre la partition finale obtenue et les indices CSJ, C3R et SDQI ont été calculés avec les paramètres  $\alpha = 1$  et  $\lambda = 0$  :  $\alpha = 1$  est la valeur de référence la plus naturelle avant toute optimisation ;  $\lambda = 0$  isole la composante compacité-séparation du C3R indépendamment du taux de rejet. Une étude de sensibilité sur ces paramètres est présentée dans la version étendue. Le Tableau 2 présente l'évaluation de cette partition au travers des indices




FIGURE 1 – Partition crédale générée.

topologiques définis dans  $M_0$ . Les indices P, R, RI mesurent la précision, le rappel et le Rand Index sur les affectations dures ; EP, ER, ERI sont leurs extensions évidentielles tenant compte des méta-clusters.

TABLEAU 2 – Évaluation de la partition crédale par les indices topologiques et standards.

| P     | R     | RI    | EP    | ER    | ERI   | CSJ    | C3R   | SDQI  |
|-------|-------|-------|-------|-------|-------|--------|-------|-------|
| 0.876 | 0.876 | 0.917 | 0.981 | 0.697 | 0.895 | -0.037 | 0.047 | 0.957 |

#### 4.1 Invariance à l'échelle et sensibilité au rejet

Pour évaluer le comportement des indices sous dilatation spatiale, nous appliquons sECMdd sur le jeu *Overlap* sous deux paramétrages :  $\delta = 100$  (aucun point rejeté,  $\mu_\emptyset \approx 0$ ) et  $\delta = 2$  (seuil resserré, 40% de la masse en conflit). Dans les deux cas, les coordonnées sont multipliées par  $\tau = 1000$  avec les paramètres ajustés proportionnellement ; les partitions avant et après dilatation sont identiques à la précision machine (diff. abs. max. =  $6.6 \times 10^{-16}$ ), confirmant l'invariance des indices  $M_0$  à l'échelle. La comparaison entre les deux paramétrages (Tableau 3) révèle un résultat plus significatif. Resserrer  $\delta$  contraint l'algorithme à rejeter davantage de points vers  $m(\emptyset)$ , ce qui dégrade la partition :  $\mu_\emptyset$  passe de 0.000 à 0.402, traduisant une augmentation de l'erreur moyenne d'affectation. Cette dégradation se manifeste également dans la non-spécificité normalisée, qui chute de 0.151 à 0.080 : les points frontière, qui devraient recevoir de la masse sur les méta-clusters  $\{C_k, C_l\}$  pour refléter l'ambiguïté réelle du jeu *Overlap*, sont à la place rejetés vers  $m(\emptyset)$ . L'algorithme substitue ainsi le rejet à la modélisation de l'ambiguïté. Les indices  $M_0$  reflètent fidèlement cette double dégradation (SDQI :

TABLEAU 3 – Indices d'évaluation sous deux paramétrages de sECMdd ( $\tau = 1000$ ).

| Paramétrage    | $\mu_\emptyset$ | $\bar{N}S$ | SDQI  | CSJ    | C3R   | Silh. |
|----------------|-----------------|------------|-------|--------|-------|-------|
| $\delta = 100$ | 0.000           | 0.151      | 0.957 | -0.037 | 0.047 | 0.509 |
| $\delta = 2$   | 0.402           | 0.080      | 0.264 | -0.744 | 2.404 | 0.510 |

0.957  $\rightarrow$  0.264; C3R : 0.047  $\rightarrow$  2.404). Le Silhouette euclidienne produit en revanche des valeurs quasi identiques dans les deux cas (0.509 vs 0.510) : en opérant après transformation pignistique, ils effacent à la fois le signal de rejet et le signal d’ambiguïté, et ne peut distinguer une partition saine d’une partition où 385 points sont rejetés.

## 4.2 Stabilité asymptotique sous bruit extrême

Afin d’évaluer la robustesse des indices face à la dégradation progressive de la structure des données, nous avons injecté un bruit de fond uniforme dans le jeu de données *Overlap*, en faisant varier le taux de points aberrants de 0% à 50% du volume total par pas de 10%. À mesure que le bruit augmente, l’algorithme repousse logiquement les masses des points aberrants vers le sommet de conflit pur  $e_0$ . La masse moyenne allouée à l’ensemble vide  $m(\emptyset)$  pour ces points converge rapidement vers 1 (env. 0.97).

Le Tableau 4 illustre la résilience du cadre  $(M_0, d_J)$ . L’indice SDQI équation (15), par sa structure multiplicative, sanctionne sévèrement la perte de cohérence géométrique globale due à l’invasion du bruit, atteignant rapidement sa borne inférieure de 0. Parallèlement, les indices CSJ et C3R offrent une traçabilité continue de la dégradation de la partition. La métrique  $\mu_\emptyset$ (Aberrations) mesure le conflit uniquement sur les points de bruit injectés, pourtant  $\mu_\emptyset$ (Global) calcule cette masse de conflit sur l’intégralité du jeu de données.

TABLEAU 4 – Impact du taux de bruit sur les métriques d’évaluation et la masse de conflit.

| Taux de bruit | Nb. Aberrations | $\mu_\emptyset$ (Aberrations) | $\mu_\emptyset$ (Global) | SDQI  | CSJ    | C3R   |
|---------------|-----------------|-------------------------------|--------------------------|-------|--------|-------|
| 0.0           | 0               | 0.000                         | 0.000                    | 0.957 | -0.037 | 0.047 |
| 0.1           | 108             | 0.970                         | 0.088                    | 0.000 | -0.114 | 0.314 |
| 0.3           | 325             | 0.974                         | 0.225                    | 0.000 | -0.212 | 1.015 |
| 0.5           | 542             | 0.976                         | 0.326                    | 0.000 | -0.276 | 1.922 |

## 4.3 Comparaison inter-algorithmes : ECM vs ECM+

Pour démontrer l’utilité d’un cadre d’évaluation indépendant de la métrique native, nous avons confronté l’algorithme Euclidien ECM et sa variante de Mahalanobis ECM+ sur deux jeux de données synthétiques à savoir : *Crossing ellipses* ( $K = 2$ ) et *Three overlapping circles* ( $K = 3$ ).

Sur le premier jeu de données (*Crossing ellipses*), la Figure 2 illustre les limites géométriques de la distance euclidienne, ECM échoue visuellement à modéliser les ellipses en forçant des centres de gravité sphériques. À l’inverse, ECM+ capture les deux sous-populations entrecroisées grâce à sa matrice de covariance adaptative. L’évaluation quantitative de ces résultats, illustrés dans le Tableau 5, révèle le biais fondamental des indices spatiaux. Sur le jeu *Crossing ellipses*, l’indice externe Adjusted Rand Index (ARI) confirme la supériorité d’ECM+ (0.76 contre 0.10 pour ECM). Pourtant, l’indice interne de Xie-Beni euclidien ( $XB_{euc}$ ) pénalise lourdement la partition produite par ECM+ (9.28) par rapport à celle, erronée, d’ECM (0.62). Cet échec survient car le  $XB_{euc}$  juge une partition issue d’une distance de Mahalanobis à travers une structure euclidienne.

TABLEAU 5 – Comparaison des métriques de validation entre ECM (Euclidien) et ECM+ (Mahalanobis).

| Jeu de données         | Algorithme | CSJ          | C3R         | SDQI        | NPQ         | $\mu_\emptyset$ | $XB_{euc}$  | $Silh_{euc}$ | ARI         | RI          | P           | R           |
|------------------------|------------|--------------|-------------|-------------|-------------|-----------------|-------------|--------------|-------------|-------------|-------------|-------------|
| Crossing ellipses      | ECM        | -1.00        | 0.27        | <b>0.71</b> | 0.96        | <b>0.01</b>     | <b>0.62</b> | <b>0.30</b>  | 0.10        | 0.55        | 0.54        | 0.58        |
| Crossing ellipses      | ECM+       | <b>0.10</b>  | <b>0.23</b> | 0.65        | <b>0.98</b> | 0.11            | 9.28        | 0.09         | <b>0.76</b> | <b>0.88</b> | <b>0.88</b> | <b>0.88</b> |
| Three overlap. circles | ECM        | <b>-0.38</b> | <b>0.13</b> | <b>0.95</b> | <b>0.95</b> | <b>0.00</b>     | <b>0.21</b> | 0.33         | <b>0.42</b> | <b>0.74</b> | <b>0.60</b> | <b>0.62</b> |
| Three overlap. circles | ECM+       | -0.39        | 0.29        | 0.56        | 0.95        | 0.05            | 0.50        | <b>0.34</b>  | 0.36        | 0.72        | 0.57        | 0.58        |

À l’inverse, nos indices topologiques, en opérant dans l’espace des masses  $M_0$ , s’affranchissent de l’espace des données d’origine. Le C3R récompense correctement ECM+ par rapport à ECM, tout comme le CSJ qui




FIGURE 2 – Crossing ellipses et three overlapping dataset.

remonte à 0.10 pour ECM+. Il convient néanmoins d’apporter une nuance sur l’indice SDQI, son facteur de cohérence topologique ( $ISI$ ) reposant sur le coefficient de corrélation de Spearman[12], il nécessite d’avoir un nombre de clusters  $K \geq 3$  pour être pleinement discriminant. Par conséquent, sur ce jeu à deux classes, le score global du SDQI ne permet pas de trancher efficacement. Cependant, sa composante de compacité intra-cluster projetée ( $NPQ$ ) compense cette limite structurale en discriminant l’erreur et en favorisant ECM+.

Enfin, l’analyse du second jeu de données (*Three overlapping circles*) met en évidence la situation inverse. Les données formant des amas circulaires, l’algorithme ECM y est adapté. L’ARI confirme que la partition d’ECM est plus fidèle à la structure réelle. L’indice SDQI parvient à identifier la meilleure approche en sanctionnant ECM+. Ce diagnostic est d’ailleurs corroboré par le C3R, dont la valeur est minimisée pour ECM.

## 5 Conclusion

Nous avons établi que  $(M_0, d_J)$  est un espace métrique borné, compact et complet, indépendant de la métrique native de tout algorithme de clustering évidentiel; ces propriétés reposent de façon essentielle sur  $D^* > 0$  [2]. Trois indices de validation ont été introduits : CSJ, C3R et SDQI, en exploitant la géométrie du simplexe  $M_0$ . Les expérimentations ont confirmé l’invariance des indices sous dilatation des données, leur dégradation continue sous injection de bruit, et leur capacité à identifier le meilleur algorithme là où les indices spatiaux classiques échouent. Deux limites ont été identifiées : l’ISI du SDQI n’est pleinement discriminant qu’à partir de  $K \geq 3$  clusters, et le paramètre  $\lambda$  du C3R requiert un critère de sélection fondé sur le taux de conflit attendu, objet d’une étude approfondie dans une version étendue de ce travail.

### Remerciements :

Ce travail a bénéficié d’une aide de l’État gérée par l’Agence Nationale de la Recherche au titre du programme d’Investissements d’Avenir portant la référence "ANR-20-SFRI-0003".

## Références

- [1] B. Albert, V. Antoine, and J. Koko. ECM+ : An improved evidential c-means with adaptive distance. *Fuzzy Sets and Systems*, 498 :109168, 2025.
- [2] M. Bouchard, A.-L. Jousselme, and P.-E. Doré. A proof for the positive definiteness of the jaccard index matrix. *International Journal of Approximate Reasoning*, 54(5) :615–626, 2013.
- [3] Haïm Brezis. *Analyse fonctionnelle : théorie et applications*. Éditions Masson, Paris, 1983.
- [4] R. J. G. B. Campello and E. R. Hruschka. A fuzzy extension of the silhouette width criterion for cluster analysis. *Fuzzy Sets and Systems*, 157(21) :2858–2875, 2006.
- [5] John C. Caruso and Norman Cliff. Empirical size, coverage, and power of confidence intervals for Spearman’s rho. *Educational and Psychological Measurement*, 57 :637–654, 1997.
- [6] F. Cuzzolin. *The Geometry of Uncertainty : The Geometry of Imprecise Probabilities*. Artificial Intelligence : Foundations, Theory, and Algorithms. Springer, 2021.
- [7] Ling Huang, Su Ruan, and Thierry Denœux. Application of belief functions to medical image segmentation : A review. *Information fusion*, 91 :737–756, 2023.
- [8] Anne-Laure Jousselme, Dominic Grenier, and Éloi Bossé. A new distance between two bodies of evidence. *Information Fusion*, 2(2) :91–101, 2001.
- [9] Arnaud Martin. About conflict in the theory of belief functions. In *Belief Functions : Theory and Applications : Proceedings of the 2nd International Conference on Belief Functions, Compiègne, France 9-11 May 2012*, pages 161–168. Springer, 2012.
- [10] M.-H. Masson and T. Denœux. ECM : An evidential version of the fuzzy c-means algorithm. *Pattern Recognition*, 41(4) :1384–1397, 2008.
- [11] P. J. Rousseeuw. Silhouettes : A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20 :53–65, 1987.
- [12] Patrick Schober, Christa Boer, and Lothar A. Schwarte. Correlation coefficients : Appropriate use and interpretation. *Anesthesia & Analgesia*, 126(5) :1763–1768, 2018.
- [13] J. Simon. *Banach, Fréchet, Hilbert and Neumann Spaces*. Analysis for PDEs Set, Vol. 1. ISTE Ltd and John Wiley & Sons, 2017.
- [14] Armel Soubeiga, Violaine Antoine, Alice Corteval, Nicolas Kerckhove, Sylvain Moreno, Issam Falih, and Jules Phalip. Clustering and interpretation of time-series trajectories of chronic pain using evidential c-means. *Expert Systems with Applications*, 260 :125369, 2025.
- [15] Xuanli Lisa Xie and Gerardo Beni. A validity measure for fuzzy clustering. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 13(8) :841–847, 1991.
- [16] Zuowei Zhang, Yiru Zhang, Hongpeng Tian, Arnaud Martin, Zhunga Liu, and Weiping Ding. A survey of evidential clustering : Definitions, methods, and applications. *Information Fusion*, 115 :102736, 2025.
- [17] K. Zhou, A. Martin, Q. Pan, and Z.-G. Liu. ECMdd : Evidential c-medoids clustering with multiple prototypes. *Pattern Recognition*, 60 :239–257, 2016.
- [18] Kuang Zhou, Arnaud Martin, Quan Pan, and Zhun-ga Liu. Median evidential c-means algorithm and its application to community detection. *Knowledge-Based Systems*, 74 :69–88, 2015.